

数据提取与合并 说明文档

概述

本项目从 CSMAR 数据库的多个 Excel 数据表中，提取 18 家 AI 相关上市公司的关键财务与市场指标，合并为一个统一的 CSV 文件，供后续研究使用。

目标公司

来源：`raw_data/filtered_tobinq.xlsx`，共 **18** 家公司，覆盖 2020Q4-2024 时间段。

Stkcd	公司简称
938	紫光股份
977	浪潮信息
2230	科大讯飞
2362	汉王科技
300002	神州泰岳
300033	同花顺
300229	拓尔思
300308	中际旭创
300339	润和软件
300394	天孚通信
300418	昆仑万维
300474	景嘉微
300502	新易盛
300624	万兴科技
601138	工业富联
601360	三六零
603019	中科曙光
688256	寒武纪

数据源与提取列

从以下 6 个 CSMAR 数据表中各提取指定列：

数据表	文件	提取列 (Excel 列号)	输出列名	CSMAR 字段编码
盈利能力表	盈利能力.xlsx	AA列	ROE	F050502B
发展能力表	发展能力.xlsx	Z列	净利润增长率	F081001B
发展能力表	发展能力.xlsx	AI列	营业收入增长率	F081601B
偿债能力表	偿债能力.xlsx	U列	资产负债率	F011201A
资产负债表	资产负债表.xlsx	CC列	总资产	A001000000
利润表	利润表.xlsx	AO列	研发投入	B001216000
TobinQ 表	tobinq.xlsx	AB列	TobinQ	F100903A

数据处理逻辑

1. 源数据特征

- 各 Excel 文件第 1 行为英文列名，第 2、3 行为中文字段描述和单位说明，实际数据从第 4 行开始
- Stkcd (股票代码) 在大表中为零填充字符串 (如 "000938")，在 filtered_tobinq.xlsx 中为整数 (如 938)
- 大部分表包含 Typrep 列，区分合并报表 (A) 和母公司报表 (B)

2. 处理步骤

- 读取目标公司列表：从 filtered_tobinq.xlsx 获取 18 家公司的 Stkcd
- 逐表提取：
 - 使用 usecols 参数只读取所需列 (Stkcd、Accper、Typrep、目标数据列)，避免加载整个大文件
 - 使用 skiprows=[1,2] 跳过中文描述行
 - 过滤只保留合并报表 (Typrep='A')，tobinq.xlsx 无此列则跳过
 - 将 Stkcd 转为整数格式，匹配目标公司
- 合并：按 Stkcd + Accper (会计期间) 逐步 outer merge
- 关联公司简称并整理列顺序
- 输出 CSV 文件

输出文件

- 路径：raw_data/merged_data.csv
- 编码：UTF-8 with BOM (utf-8-sig)

- 行数：522 行
- 列结构：

列名	说明
Stkcd	股票代码
ShortName	公司简称
Accper	会计期间（日期）
ROE	净资产收益率
净利润增长率	净利润同比增长率
营业收入增长率	营业收入同比增长率
资产负债率	资产负债率
总资产	总资产（元）
研发投入	研发投入（元）
TobinQ	托宾Q值

项目脚本

脚本	目录	用途
<code>extract_and_merge.py</code>	<code>utils/</code>	数据提取与合并（主脚本）
<code>check_excel_columns.py</code>	<code>Inspect/</code>	验证各 Excel 文件的列位置是否正确
<code>debug_stkcd_match.py</code>	<code>Inspect/</code>	调试 Stkcd 匹配问题
<code>debug_duplicates.py</code>	<code>Inspect/</code>	调试数据重复问题（Typrep）

使用方法

```
1 # 运行数据合并
2 python utils/extract_and_merge.py
```

注意事项

- 部分日期（如 `2020-01-01`、`2021-01-01`）仅有资产负债表和利润表数据，其他指标为空值（NaN），这是资产负债表中的期初数据
- 原始 Excel 文件较大（总计约 500MB），脚本运行约需 3-5 分钟